

Embedding

의미를 좌표로 바꾸는 기술


임베딩은 텍스트, 이미지, 오디오 같은 객체를
연속 벡터 공간의 점으로 표현해
모델이 유사성과 맥락을 더 잘 읽도록 돕습니다.

핵심: 비슷한 것은 가까이 놓인다

검색

추천

챗봇



Embedding = 의미를 보존한 좌표 표현

복잡한 데이터를 벡터로 바꿔 다운스트림 작업을 쉽게 만든다.

임베딩은 복잡한 데이터를 숫자 좌표로 압축한다

임베딩을 객체를 연속 벡터 공간의 점으로 표현하는 수단으로 설명한다.

객체 -> 벡터

단어, 이미지, 오디오처럼 형태가 다른 입력도
숫자 배열로 바뀌면 같은 계산 체계에서 다룰
수 있다.


가까움 = 유사성

벡터 공간에서 서로 가까운 항목일수록
의미나 문맥도 비슷하다고 해석한다.

학습된 표현

명시적 규칙보다 데이터에서
패턴을 배운다.

연속 벡터 공간




유사성은 거리와 방향으로 읽힌다

벡터 간 관계는 유클리드 거리, 코사인 유사도, 점곱 같은 방식으로 비교할 수 있다.

1. 입력 데이터는 고차원일 수 있지만 모델은 이를 n 차원 좌표로 읽는다.
2. 다른 벡터와의 거리와 방향을 비교해 유사한 항목을 찾는다.
3. IBM 예시처럼 '아빠'와 '아버지'는 '엄마'보다 더 가깝게 배치될 수 있다.

예시 벡터 맵



유클리드 거리

코사인 유사도

점곱

임베딩이 중요한 다섯 가지 이유

임베딩은 이해와 계산 효율을 동시에 높인다.

의미론적 표현

단어·이미지·노드 사이의
관계와 의미를 더 풍부하게 담는다.

차원 축소

고차원 데이터를 더 다루기 쉬운
연속 표현으로 바꿔 계산을 가볍게 한다.

일반화 개선

보지 못한 예시에도 패턴을 이어 읽어
모델의 적용 범위를 넓힌다.

시각화

클러스터와 관계를 2D/3D로 투영해
데이터 구조를 직관적으로 볼 수 있다.

효율적 학습

임베딩 레이어가 범주형 입력을
학습 가능한 연속 벡터로 바꿔 준다.

표현력 + 효율성

단어에서 그래프까지 거의 모든 객체를 임베딩할 수 있다

데이터 타입이 달라도 목표는 같다. 의미 있는 관계를 보존한 표현을 만드는 것이다.

단어

Word2Vec, GloVe,
FastText처럼
단어의 의미 관계와 문맥
을 담는다.

텍스트

문장·단락·문서를 하나의
벡터로
표현해 검색과 분류에 활용
한다.

이미지

시각 특징을 압축해
분류·검색·인식 작업에 쓴
다.

오디오

음성·음향 특징을 벡터화해
인식과 분류 작업을 돕는
다.

그래프

노드와 링크 구조를 표현해
링크 예측과 커뮤니티 탐지
에 쓴다.

모달리티가 달라도 추상화는 같다

입력 객체 -> 벡터 표현 -> 유사성 기반 작업


공통 목표: 관계 보존

생성 과정은 모델 선택에서 애플리케이션 통합까지 이어진다

데이터 타입에 따라 세부 구현은 달라도, 전체 흐름은 비슷하다.

핵심 흐름

1) 데이터와 작업에 맞는 모델을 고른다 -> 2) 입력을 모델 형식에 맞게 준비한다 -> 3) 모델을 로드하거나 학습한다 -> 4) 각 객체의 벡터를 생성한다 -> 5) 검색, 추천, 분류 같은 작업에 연결한다.



목표: 관계가 보존되는 연속 벡터 공간

실제 시스템에서는 '유사한 것을 더 잘 찾는 능력'으로 나타난다

임베딩은 검색·추천·인식·질문응답의 공통 기반이다.

NLP

감성 분석, 질문응답, 문서 유사성 비교

컴퓨팅 비전

이미지 분류, 이미지 검색, 얼굴 인식

추천 시스템

사용자-항목 매칭과
개인화 추천

발표용 한 장 요약

- raw data를 벡터 공간으로 옮기면
의미 기반 검색과 매칭이 쉬워진다.
- 텍스트, 이미지, 오디오, 그래프처럼
서로 다른 입력도 같은 추상화 위에서 다룰 수 있다.
- 그래서 검색 엔진, 추천 시스템, 챗봇,
사기 탐지 같은 애플리케이션의 기반이 된다.

Embedding

의미를 보존한 채
데이터를
계산 가능한 좌표로
옮기는 인터페이스